

АТД «Словарь»

- Реализация группы операций над данными:
 - хранение
 - добавление
 - удаление
 - поиск (может быть удачным и неудачным)
 - сортировка
 - поиск минимального (максимального, среднего)
 - ...

Поиск. Способы хранения данных

Способ	Худший случай			Средний случай		
	Вставка	Поиск	Выбор	Вставка	Поиск +	Поиск -
Массив, индексированный ключами	O(1)	O(1)	O(M)	O(1)	O(1)	O(1)
Упорядоченный массив	O(N)	O(N)	O(1)	O($N/2$)	O($N/2$)	O($N/2$)
Упорядоченный список	O(N)	O(N)	O(N)	O($N/2$)	O($N/2$)	O($N/2$)
Неупорядоченный массив	O(1)	O(N)	O($N \log_2 N$)	O(1)	O($N/2$)	O(N)
Неупорядоченный список	O(1)	O(N)	O($N \log_2 N$)	O(1)	O($N/2$)	O(N)
Бинарный поиск	O(N)	O($\log_2 N$)	O(1)	O($N/2$)	O($\log_2 N$)	O($\log_2 N$)
Бинарное дерево	O(N)	O(N)	O(N)	O($\log_2 N$)	O($\log_2 N$)	O($\log_2 N$)
Рандомизированное дерево	O(N)*	O(N)*	O(N)*	O($\log_2 N$)	O($\log_2 N$)	O($\log_2 N$)
Сбалансированное дерево	O($\log_2 N$)	O($\log_2 N$)	O($\log_2 N$)	O($\log_2 N$)	O($\log_2 N$)	O($\log_2 N$)
Хеш-таблица	O(1)	O(N)*	O($N \log_2 N$)	O(1)	O(1)	O(1)

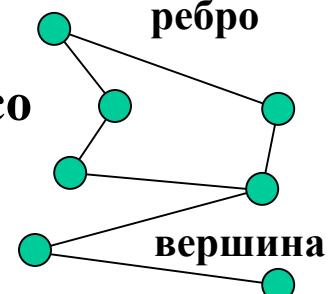
Деревья. Основные понятия

Граф – это конечное множество вершин (узлов) вместе со множеством ребер (дуг), соединяющих пары различных вершин.

Дерево – это связный ациклический граф.

Дерево – это или пустое множество вершин, или [ориентированный] ациклический граф, в котором существует одна вершина, в которую не входит ни одна дуга, в каждую из оставшихся входит ровно одна дуга и существует единственный путь из корня в любую вершину.

Корневое дерево – это множество узлов, среди которых существует один особый узел (корень), а все остальные делятся на n подмножеств T_i , каждое из которых является деревом. Множества T_1, \dots, T_n – называются поддеревьями корня. Если порядок существенен [и организован], то дерево называется упорядоченным.



Деревья. Основные понятия. Седжвик

Дерево – это непустая коллекция верши и ребер, удовлетворяющих определенным требованиям. *Вершина* – это простой объект, с которым может быть связана какая-либо информация; *ребро* – это связь между двумя вершинами. *Путь* в дереве – это список конкретных вершин, в котором следующие друг за другом вершины соединяются ребрами дерева.

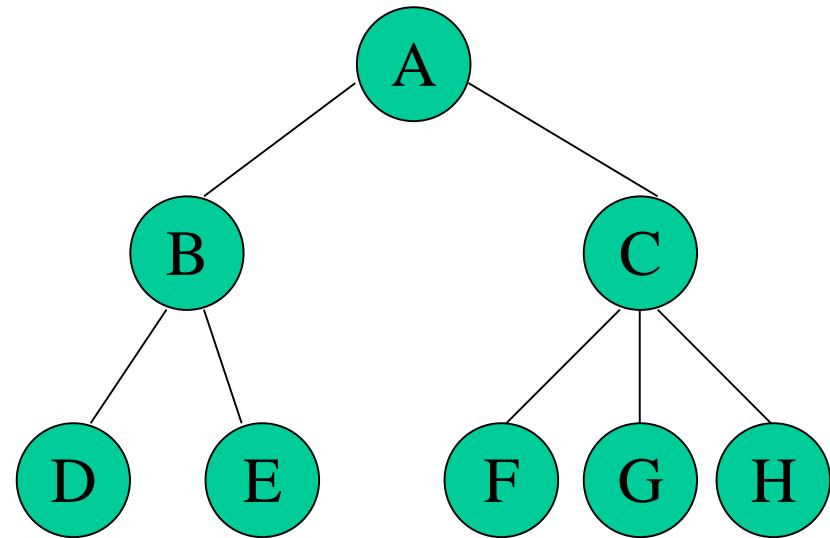
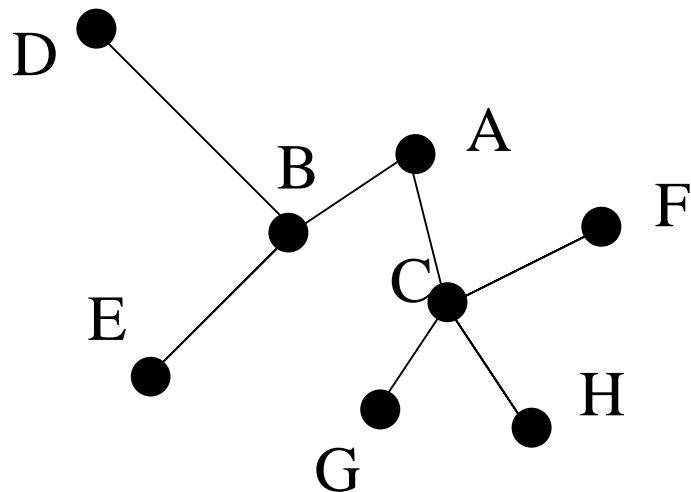
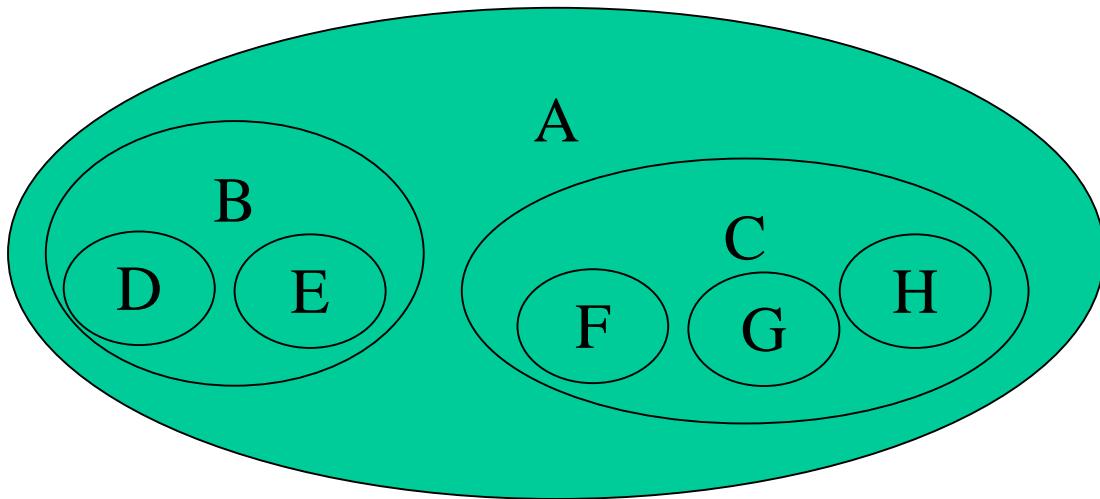
Дерево с корнем (корневое) – это дерево, в котором один узел назначен корнем. Свободные деревья.

Существует *единственный путь* между корнем или любым другим узлом. Направление не важно, обычно от корня. Каждый узел, кроме корня имеет *родительский узел*. Дочерние узлы, потомки. Листья или терминальные узлы. Нетерминальные узлы – это узлы, имеющие хотя бы одного потомка. Упорядоченное дерево – это корневое дерево, в котором определен порядок следования дочерних узлов каждого узла.

Если каждый узел должен иметь конкретно количество дочерних, то говорят об *M-арном дереве*. Внешние узлы не имеют дочерних. Внешние узлы могут выступать как *фиктивные*, на которые ссылаются узлы, не имеющие заданного количества дочерних узлов.

Лист в M-рном дереве – это внутренний узел, все дочерние узлы которого являются внешними.

Деревья. Графическое представление



Является ли структура
«дерево» – АТД?

Бинарные деревья. Основные понятия.

Седжвик

Бинарное дерево – это упорядоченное корневое дерево, которое либо внешний узел, либо внутренний, связанный с парой бинарных деревьев, называемых левым и правым поддеревьями этого узла.

Бинарное дерево с N внутренними узлами имеет:

$N + 1$ внешних узлов;

$2N$ связей, из которых $N - 1$ связей с внутренними узлами и $N + 1$ связей с внешними узлами;

длина внешнего пути = длина внутреннего пути + $2N$;

$\log_2 N \leq$ высота дерева $\leq N - 1$;

$M \log_2(N/4) \leq$ длина внутреннего пути $\leq N(N-1)/2$

....

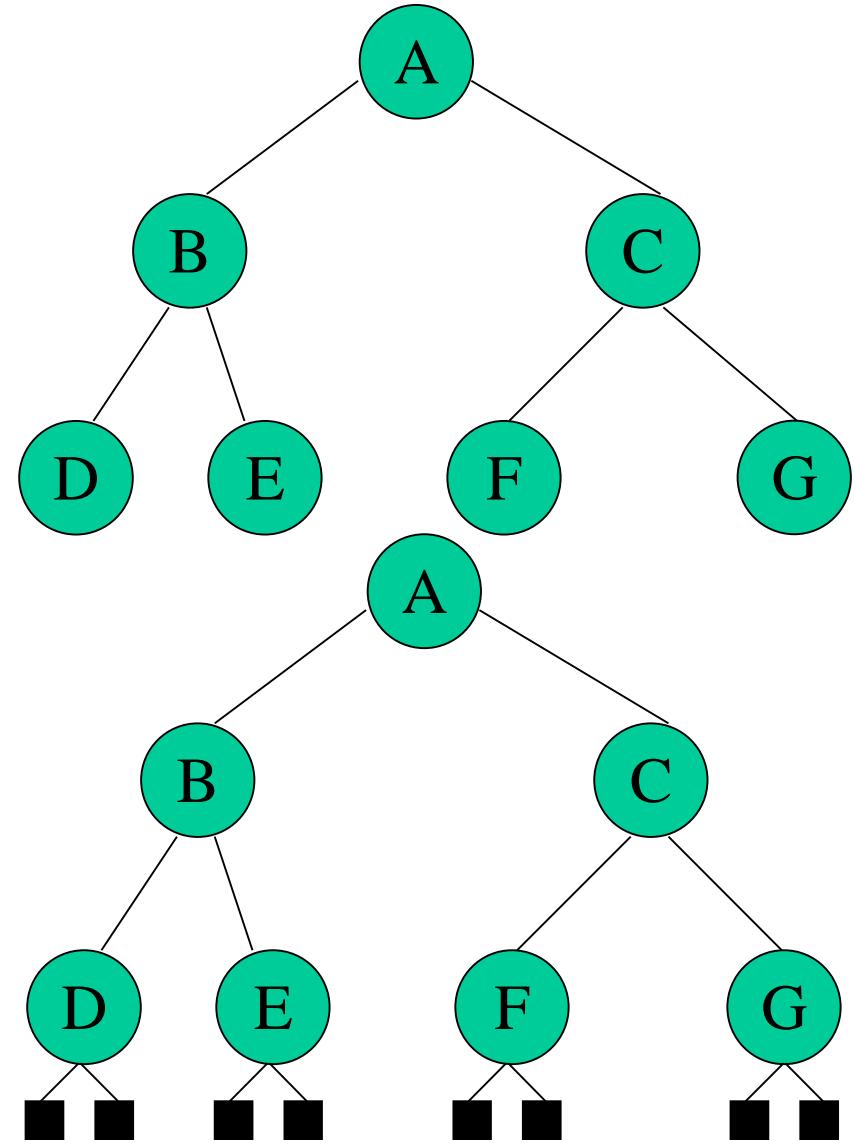
Уровень узла в дереве на единицу выше уровня родительского узла (уровень корня – 0). Высота дерева – это максимальный уровень. Длина пути дерева – это сумма уровней всех узлов дерева. Длина внутреннего (внешнего) пути дерева – это сумма уровней всех внутренних (внешних) узлов дерева.

Представление деревьев

- ссылочные структуры
- массив (см. «пирамида»)
- упакованный массив
- польская запись
- любые способы представления графов (но все эффективны) ! (см. далее)

Сылочные структуры

```
struct Node {  
    Item Data;  
    struct Node * Child0;  
    struct Node * Child1;  
};  
/*-----*/  
  
struct Node {  
    Item Data;  
    struct Node ** Childs;  
};  
  
struct Node {  
    Item Data;  
    struct Node * Left;  
    struct Node * Right;  
};
```



Упакованный массив

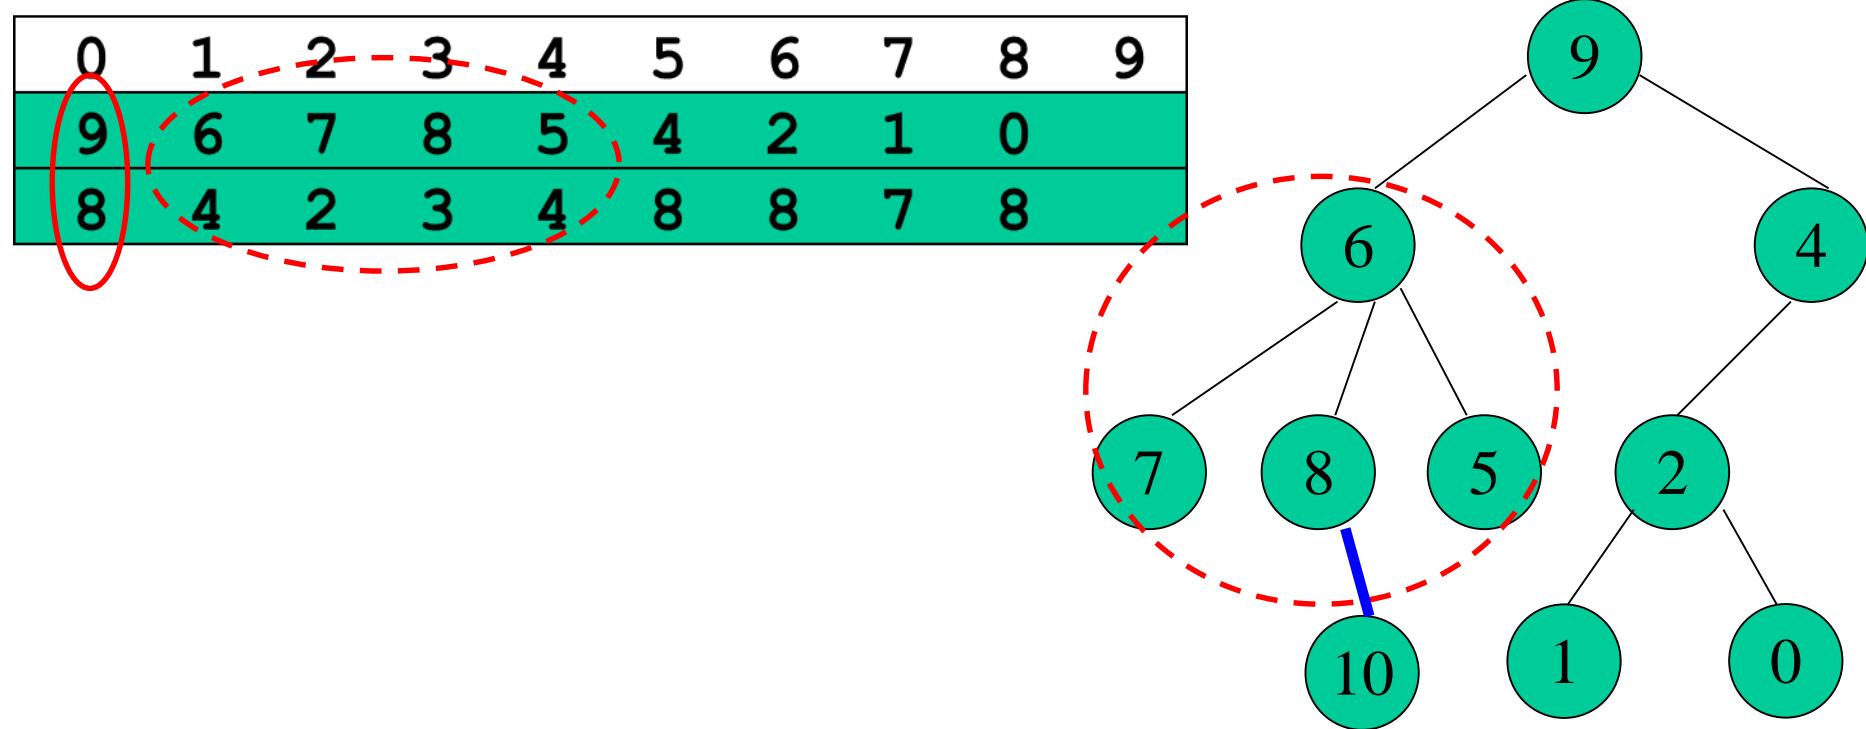
Все располагаются в массиве так, что все узлы поддерева данного узла расположены вслед за этим узлом.

Вместе с каждым узлом хранится информация о последнем узле поддерева данного узла.

```
struct {  
    Item Data;          //например, целое число  
    int LastNodeID;    //индекс узла, последнего в  
                      //данном поддереве  
};
```

0	1	2	3	4	5	6	7	8	9
9	6	7	8	5	4	2	1	0	
8	4	2	3	4	8	8	7	8	

Графическое представление упакованного массива



Польская запись

Все располагаются в массиве так, что все узлы поддерева данного узла расположены вслед за этим узлом.

Вместе с каждым узлом хранится информация о типе узла, т.е. о количестве типе связей: потомков нет, один левый или правый потомок (различают для деревьев поиска), оба потомка.

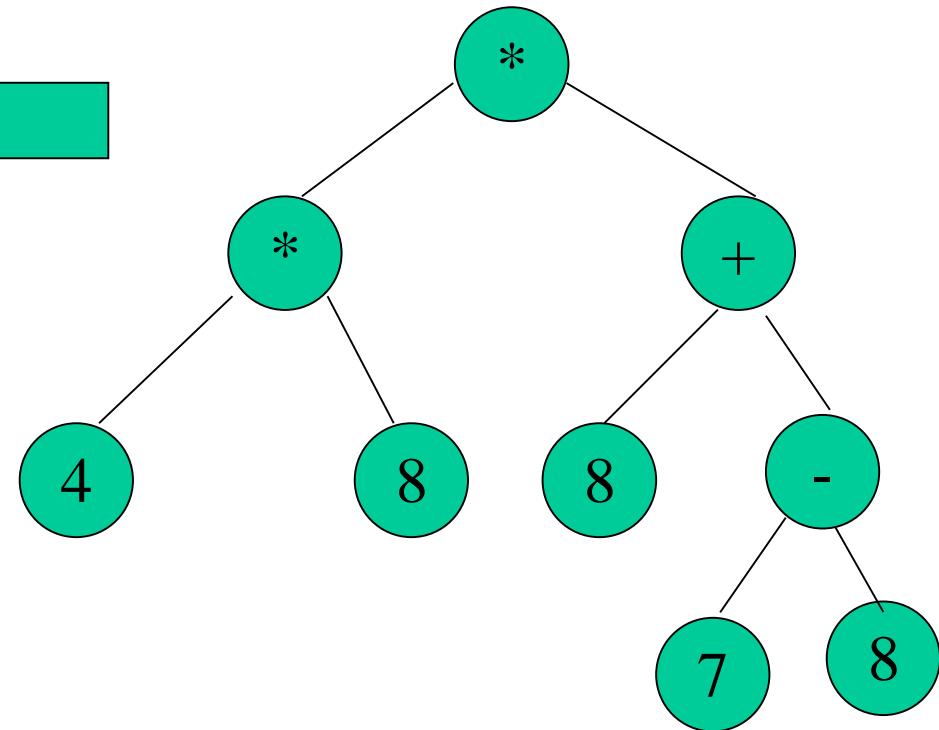
```
struct {  
    Item Data;  
    char Childs;  
};
```

Если информация о количестве потомков прямо следует из значения узла, то можно «тип» избыточен.

*	*	4	8	+	8	-	7	8
---	---	---	---	---	---	---	---	---

Графическое представлениепольской записи

```
* * 4 8 + 8 - 7 8
```



```
(* (* 4 8) (+ (8 (- 7 8))))
```

Обход

Обход [элементов] некоторой структуры данных – систематическое перечисление её элементов (узлов).

Перечисление может являться основой для решения каких-либо конкретных задач:

- «**сериализация**» (например, вывод на экран, в файл, массив и пр. в определенной последовательности),
- подсчет количества элементов (возможно, обладающих какими-либо свойствами),
- изменение свойств/значений всех или некоторых элементов, обладающих определенными свойствами
- и др.

Обход списка

```
struct Item {  
    Key Data;  
    struct Item * Next;  
};  
  
void VisitAllItems(struct Item * Head) {  
    // тело функции  
}
```

Обход списка

```
struct Item {  
    Key Data;  
    struct Item * Next;  
};  
  
void VisitAllItems(struct Item * Head) {  
    while (Head) {  
        DoSomething(Head);  
        Head = Head->Next;  
    }  
}
```

Бинарные деревья. Обход

Бинарное дерево – это упорядоченное корневое дерево, которое либо **внешний** узел («пустой», «фиктивный»), либо внутренний, связанный с парой бинарных деревьев, называемых левым и правым поддеревьями этого узла.

Обход дерева – систематическое перечисление его элементов (узлов).

Обход в глубину
(рекурсия, АТД «Стек»)

{ **Прямой обход** (узел, левое поддерево, правое поддерево).
Симметричный обход (левое поддерево, узел, правое поддерево).
Обратный обход (левое поддерево, правое поддерево, узел).

обход в ширину
(АТД очередь)

{ **Обход по уровням** – сверху вниз, слева направо.

Обход списка

```
struct Item {  
    Key Data;  
    struct Item * Next;  
};  
  
void VisitAllItems(struct Item * Head) {  
    if (Head) {  
        DoSomething(Head);  
        VisitAllItems(Head->Next);  
    }  
}
```

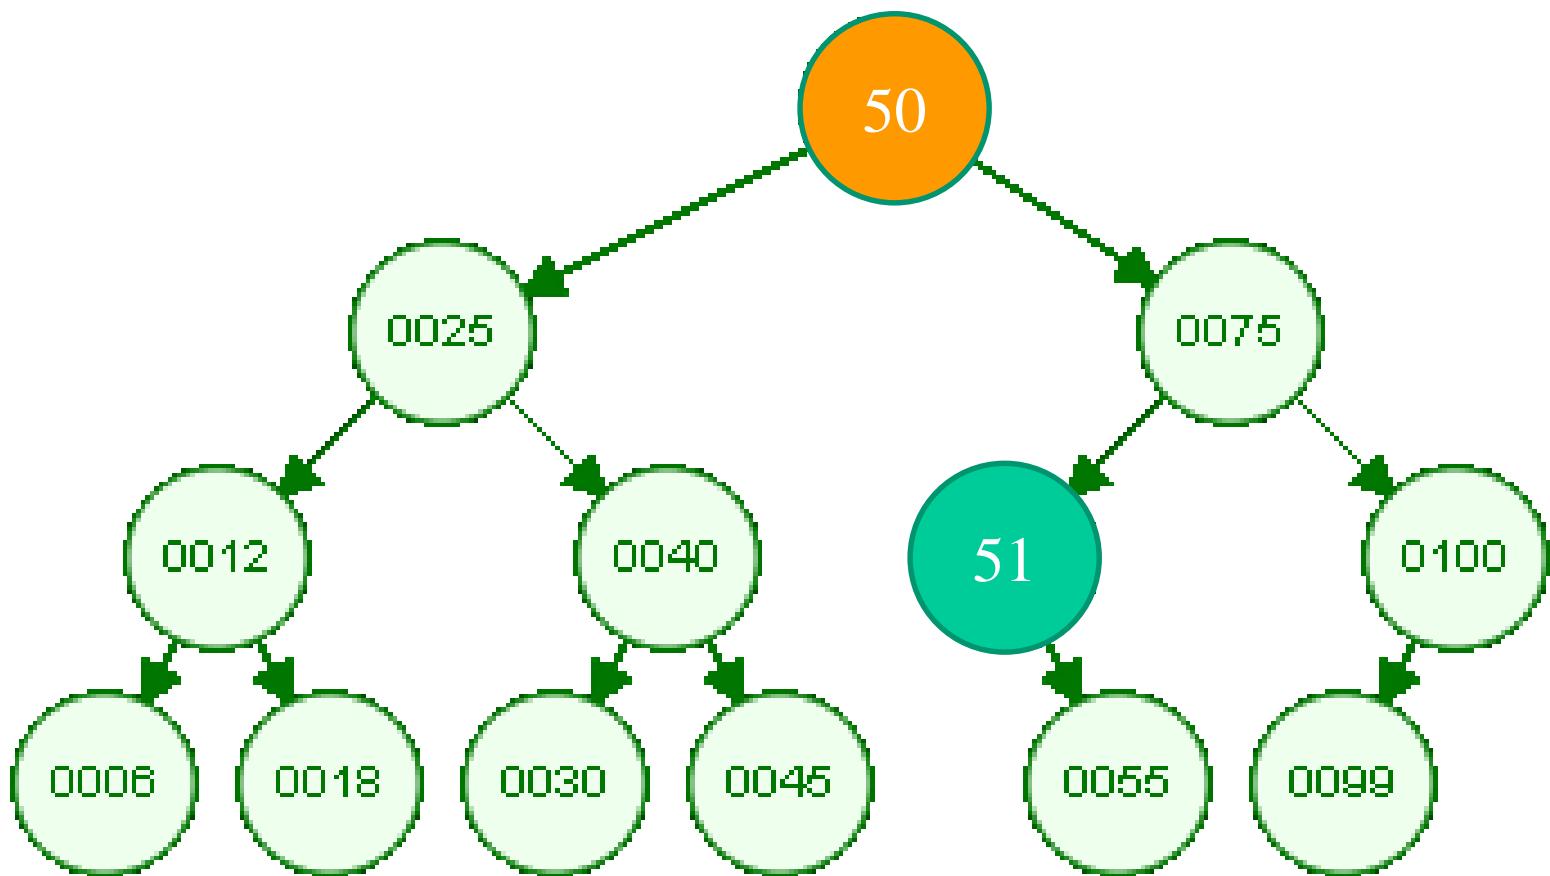
Обход дерева

```
struct Item {  
    Key Data;  
    struct Item * Left;  
    struct Item * Right;  
};  
  
void VisitAllItems(struct Item * Root) {  
    // тело функции  
}
```

Обход дерева

```
struct Item {  
    Key Data;  
    struct Item * Left;  
    struct Item * Right;  
};  
  
void VisitAllItems(struct Item * Root) {  
    if (Root) {  
        DoSomething(Root); //print("%d ", Root->Data);  
        VisitAllItems(Root->Left);  
        VisitAllItems(Root->Right);  
    }  
}
```

Обход дерева



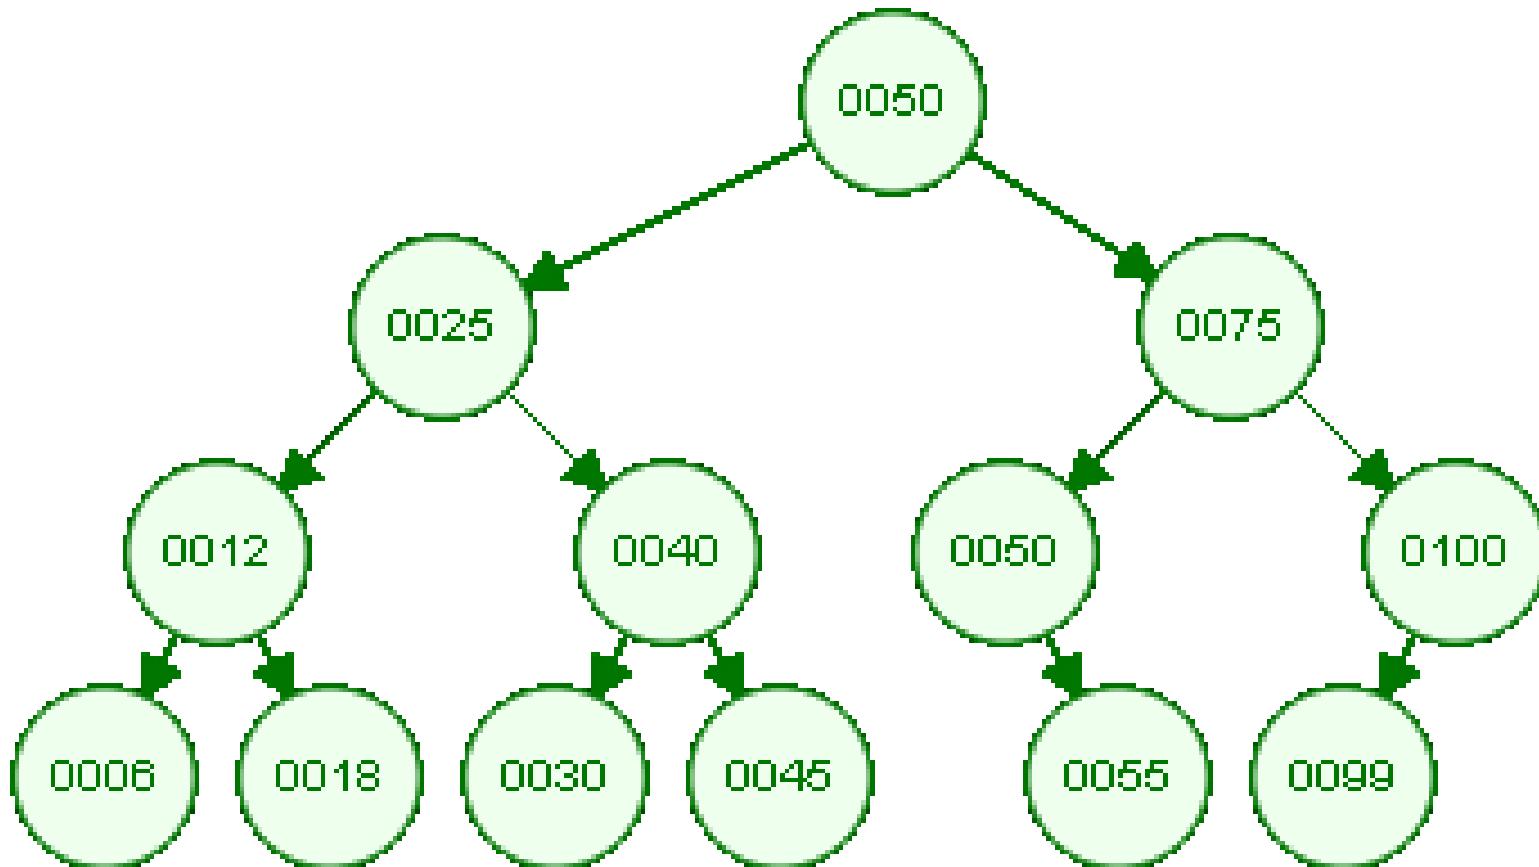
Прямой: 50 25 12 6 18 40 30 45 75 51 55 100 99

Симметричный: 6 12 18 25 30 40 45 50 51 55 75 99 100

Обратный: 6 18 12 30 45 40 25 55 51 99 100 75 50

В ширину: 50 25 75 12 40 51 100 6 18 30 45 55 99 20

Обход дерева



Прямой: 50 25 12 6 18 40 30 45 75 50 55 100 99

Симметричный: 6 12 18 25 30 40 45 50 50 55 75 99 100

Обратный: 6 18 12 30 45 40 25 55 50 99 100 75 50

В ширину:

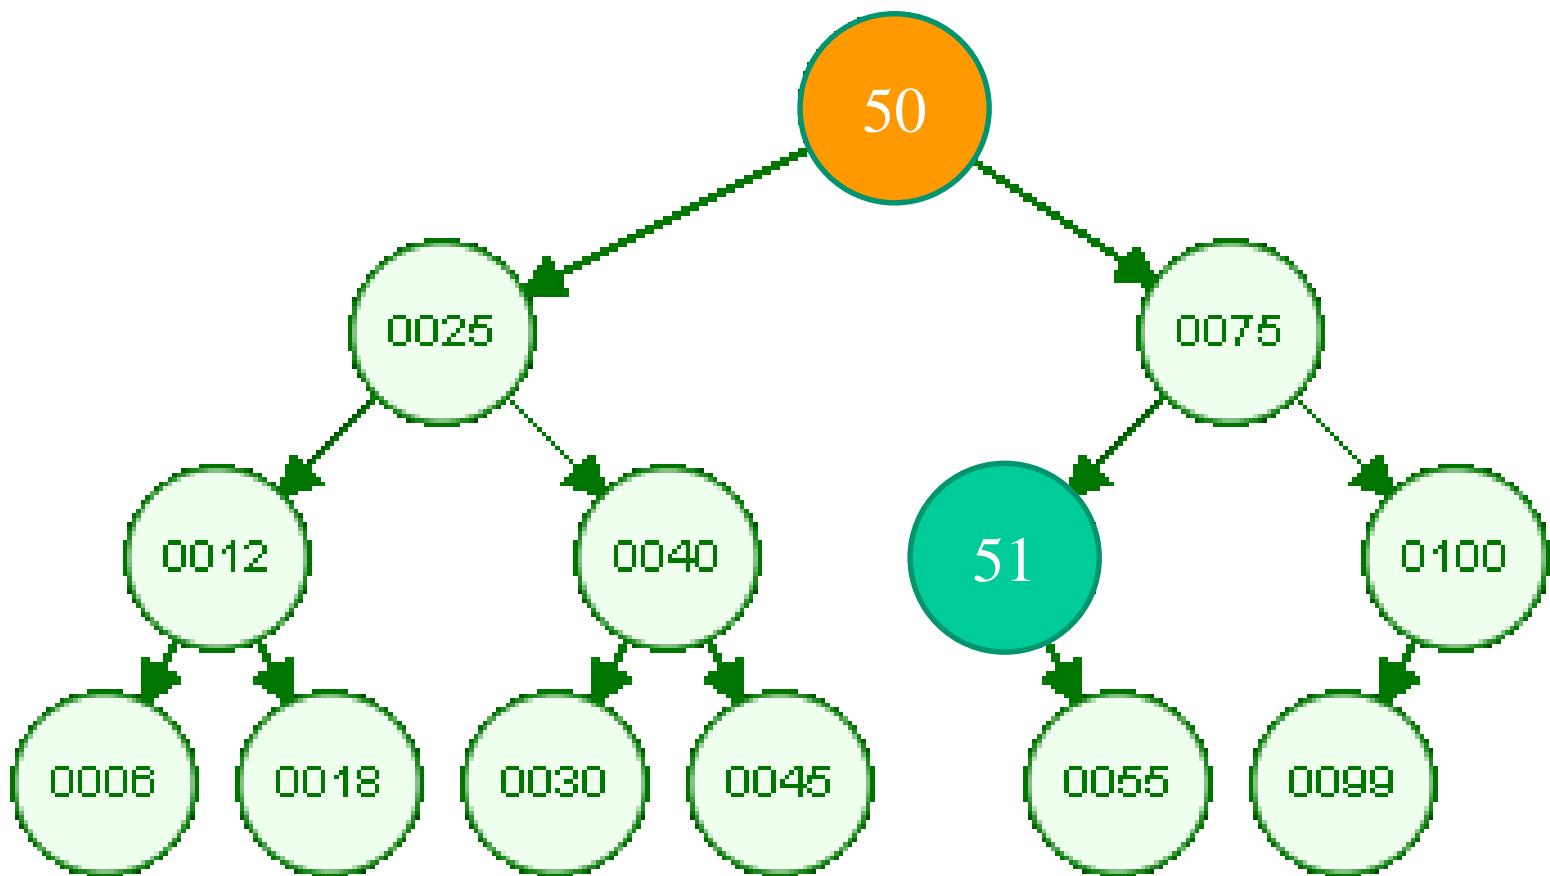
Обход дерева

```
struct Item {  
    Key Data;  
    struct Item * Left;  
    struct Item * Right;  
};  
Container C; //Count (/**/); Push (/**/); Pop (/**/);  
  
void VisitAllItems(struct Item * Root) {  
    //тело функции  
}
```

Обход дерева

```
Container C; //Count(); Push(***); Pop(***);  
  
void VisitAllItems(struct Item * Root) {  
    if (Root) Push(C, Root);  
  
    while (Count(C)) {  
        Root = Pop(C);  
        DoSomething(Root);  
        if (Root->Left) Push(C, Root->Left);  
        if (Root->Right) Push(C, Root->Right);  
    }  
}
```

Обход дерева



Прямой: 50 25 12 6 18 40 30 45 75 51 55 100 99

Симметричный: 6 12 18 25 30 40 45 50 51 55 75 99 100

Обратный: 6 18 12 30 45 40 25 55 51 99 100 75 50

В ширину: 50 25 75 12 40 51 100 6 18 30 45 55 99 24

Бинарное дерево поиска. Определение

Бинарное дерево поиска – это бинарное дерево, с каждым из внутренних узлов которого связан ключ, причем значение этого ключа больше (или равно) ключей во всех узлах левого поддерева этого и меньше (или равно) ключей во всех узлах правого поддерева. Основные операции:

- **поиск**

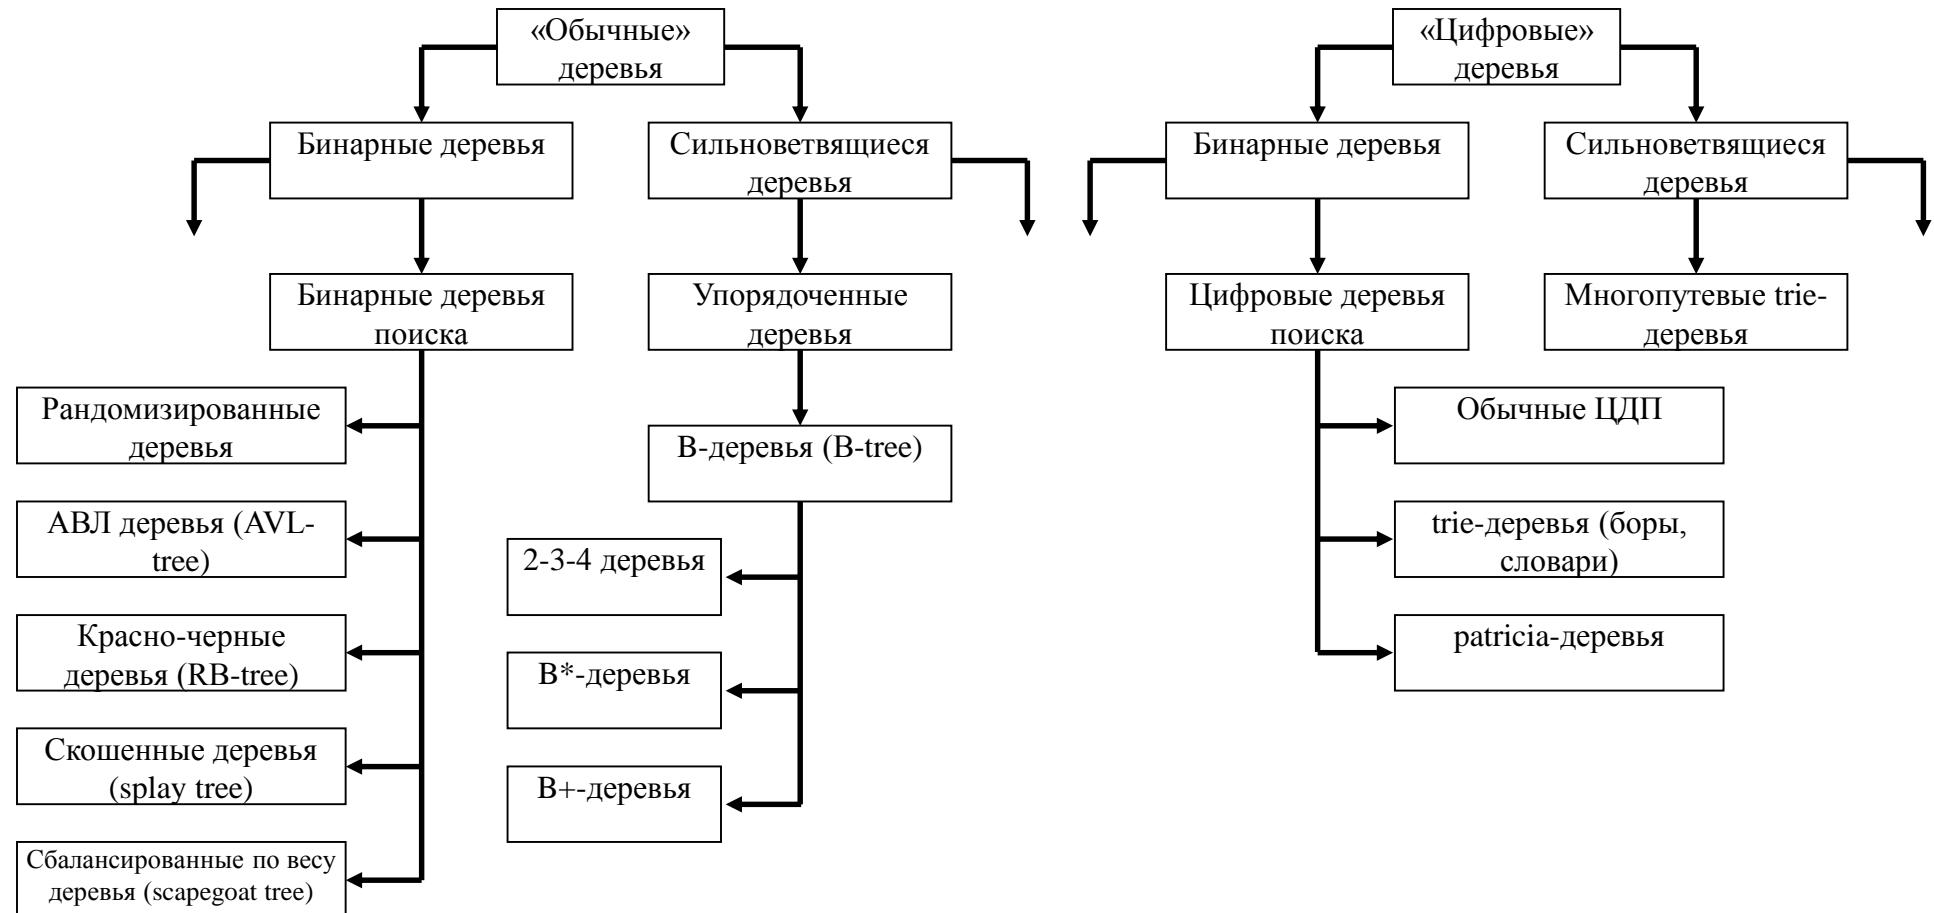
- **вставка**

- **удаление:**

1. Если удаляемый узел – лист, то удаление тривиально.
2. Если у удаляемого узла один потомок (одно поддерево), то узел удаляется, а его поддерево «подтягивается».
3. Если существуют оба под дерева, то необходимо найти узел с минимальным ключом в правом поддереве, поменять его удаляемым и затем выполнить удаление. Узел с минимальным справа ключом гарантировано будет иметь не более одного поддерева (правого), поэтому дальнейшее удаление будет соответствовать пунктам 1 или 2.

В худшем случае асимптотическая сложность операций вставки, поиска, удаления может быть равна $O(N)$, вместо средней $O(\log_2 N)$.

Сбалансированные и цифровые деревья поиска



Сбалансированные деревья поиска

Бинарное дерево называется *выровненным*, если все листья находятся на одном уровне.

Бинарное дерево называется *заполненным* (*идеально сбалансированным*), если все узлы, имеющие меньше двух потомком находятся на одном или двух уровнях. Для заполненного дерева

$$\log_2(N + 1) - 1 \leq \text{высота дерева} < \log_2(N + 1);$$

Бинарное дерево называется *полным*, если все листья находятся на одном уровне и все узлы, кроме листьев имеют ровно двух потомков:

$$\log_2(N + 1) - 1 = \text{высота дерева.}$$

Заполненные деревья наиболее эффективны при поиске, но вставка/удаление узла могут потребовать перестройки всего дерева, поэтому асимптотическая сложность в худшем случае может быть равна $O(N)$.

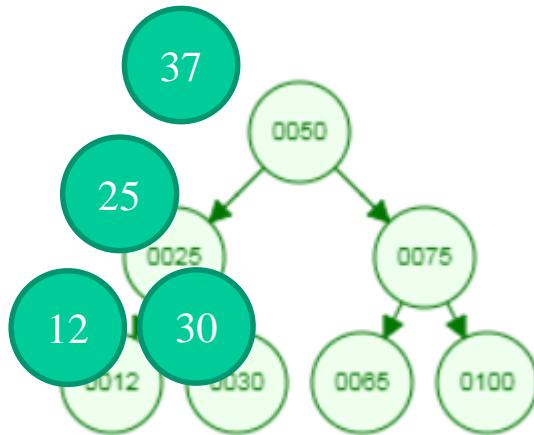
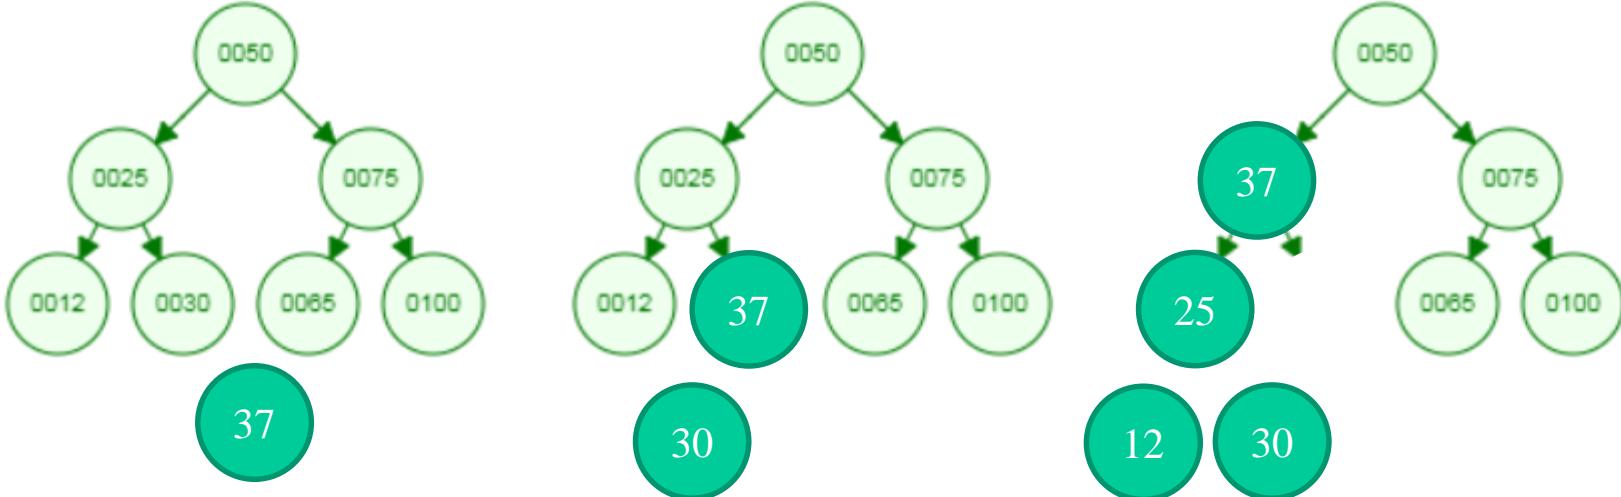
Рандомизированные бинарные деревья поиска

Построение основывается на двух операциях

1. «вращение» («поворот»)
2. вставка в корень

Обобщенный алгоритм:

случайным образом чередуется вставка узлов в листья и в корень
– с вероятностью, обратно пропорциональной количеству узлов в текущем поддереве, осуществляется вставка в его корень.



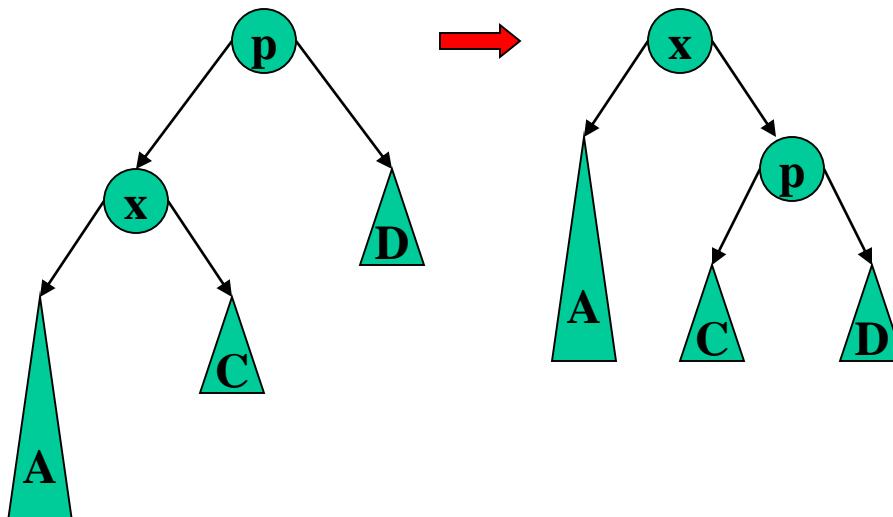
АВЛ-деревья

Разность высот поддеревьев любого узла не превышает 1. Балансировка осуществляется на основе операций одинарного и двойного поворотов.

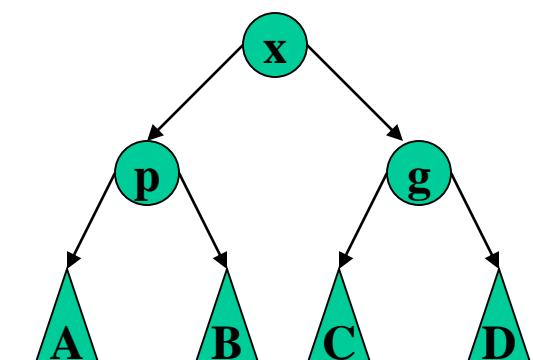
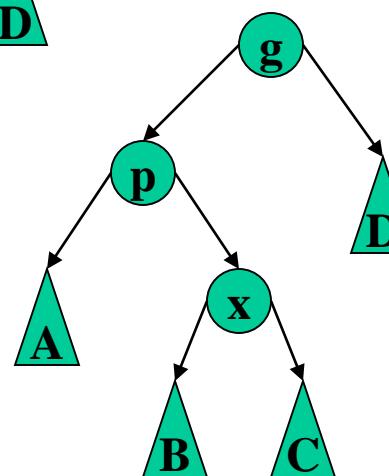
высота дерева $\leq 2\log_2 N$

(более точная оценка – высота дерева $\leq \log_{(\sqrt{5}+1)/2} 2 = 1,44\log_2 N$)

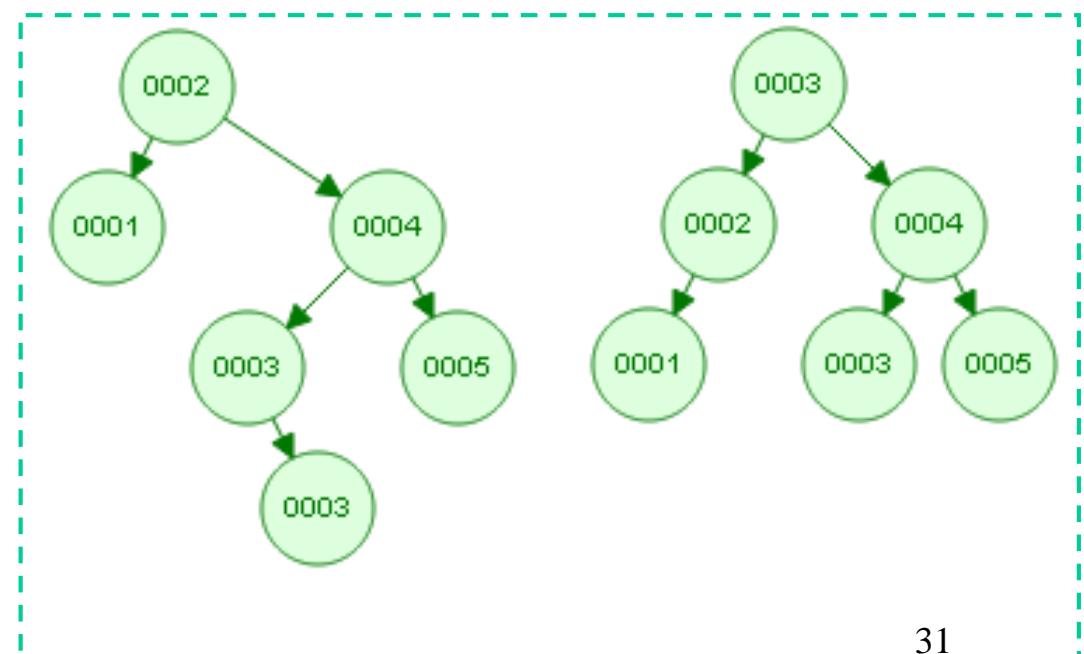
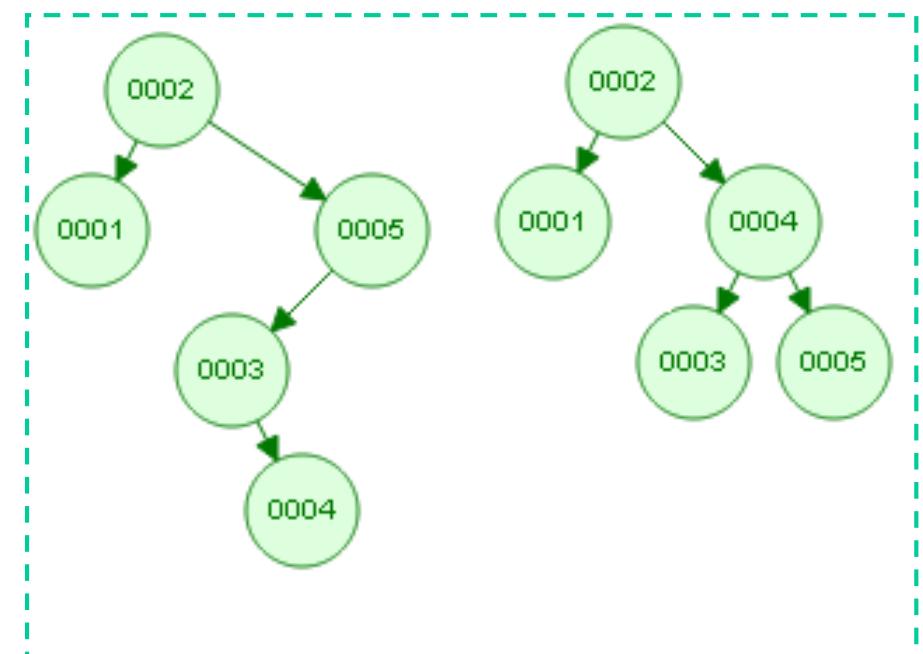
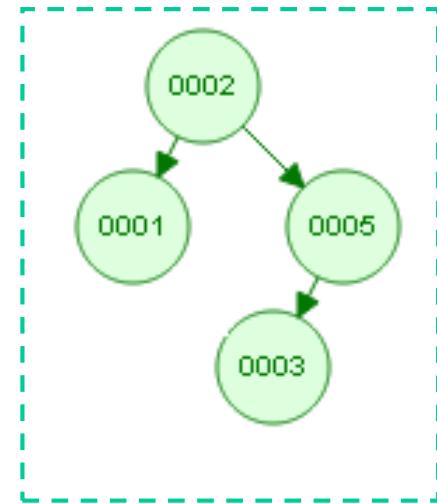
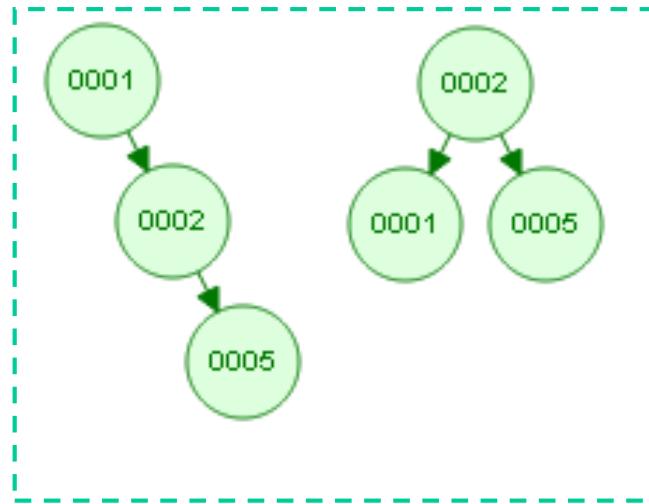
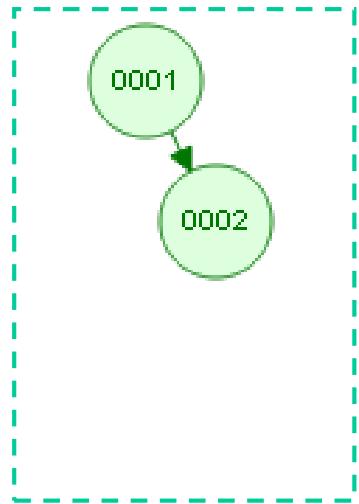
Одинарный поворот



Двойной поворот



АВЛ-деревья



Красно-черные деревья

- **каждый узел дерева либо красный, либо черный**
- **каждый внешний узел – черный**
- **если узел красный, то его потомки – черные**
- **количество черных узлов, встречающихся в любом пути от корню к листьям – одинаковое (называется «черной» высотой).**

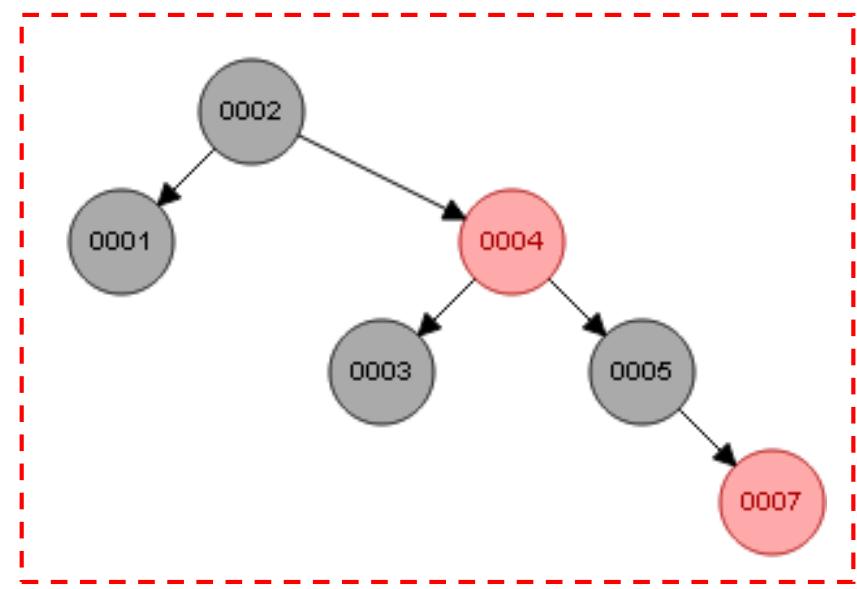
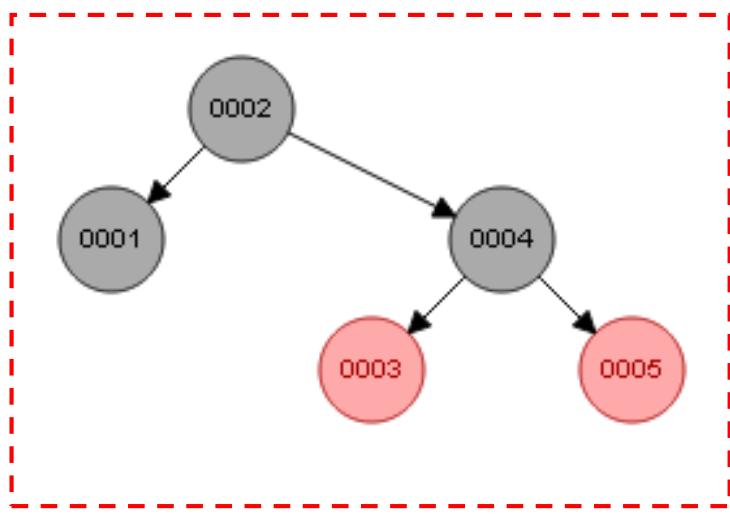
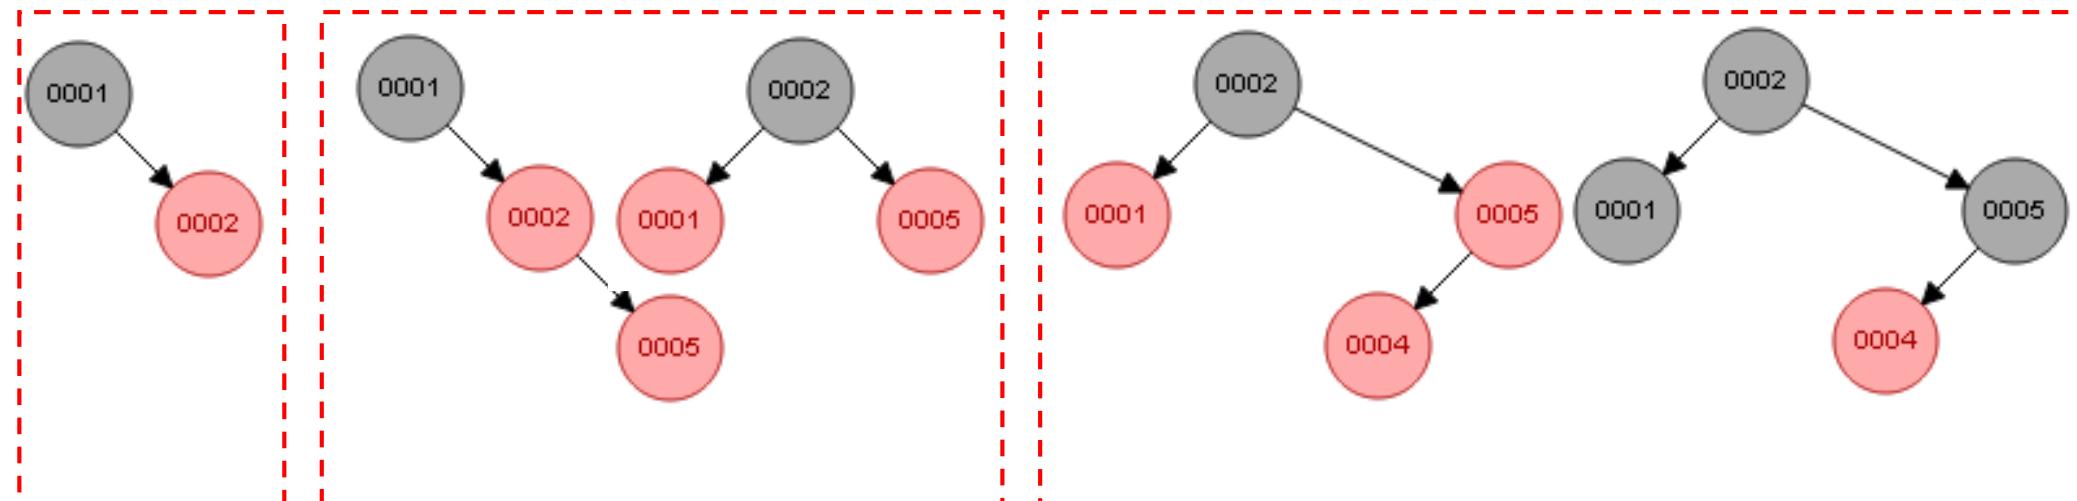
Длина максимального пути не более, чем в 2 раза больше любого другого в дереве.

Средняя высота $1,002\log_2 N$, в худшем случае – $2(\log_2 N + 1)$.

Обеспечение свойств при вставке/удалении достигается путем

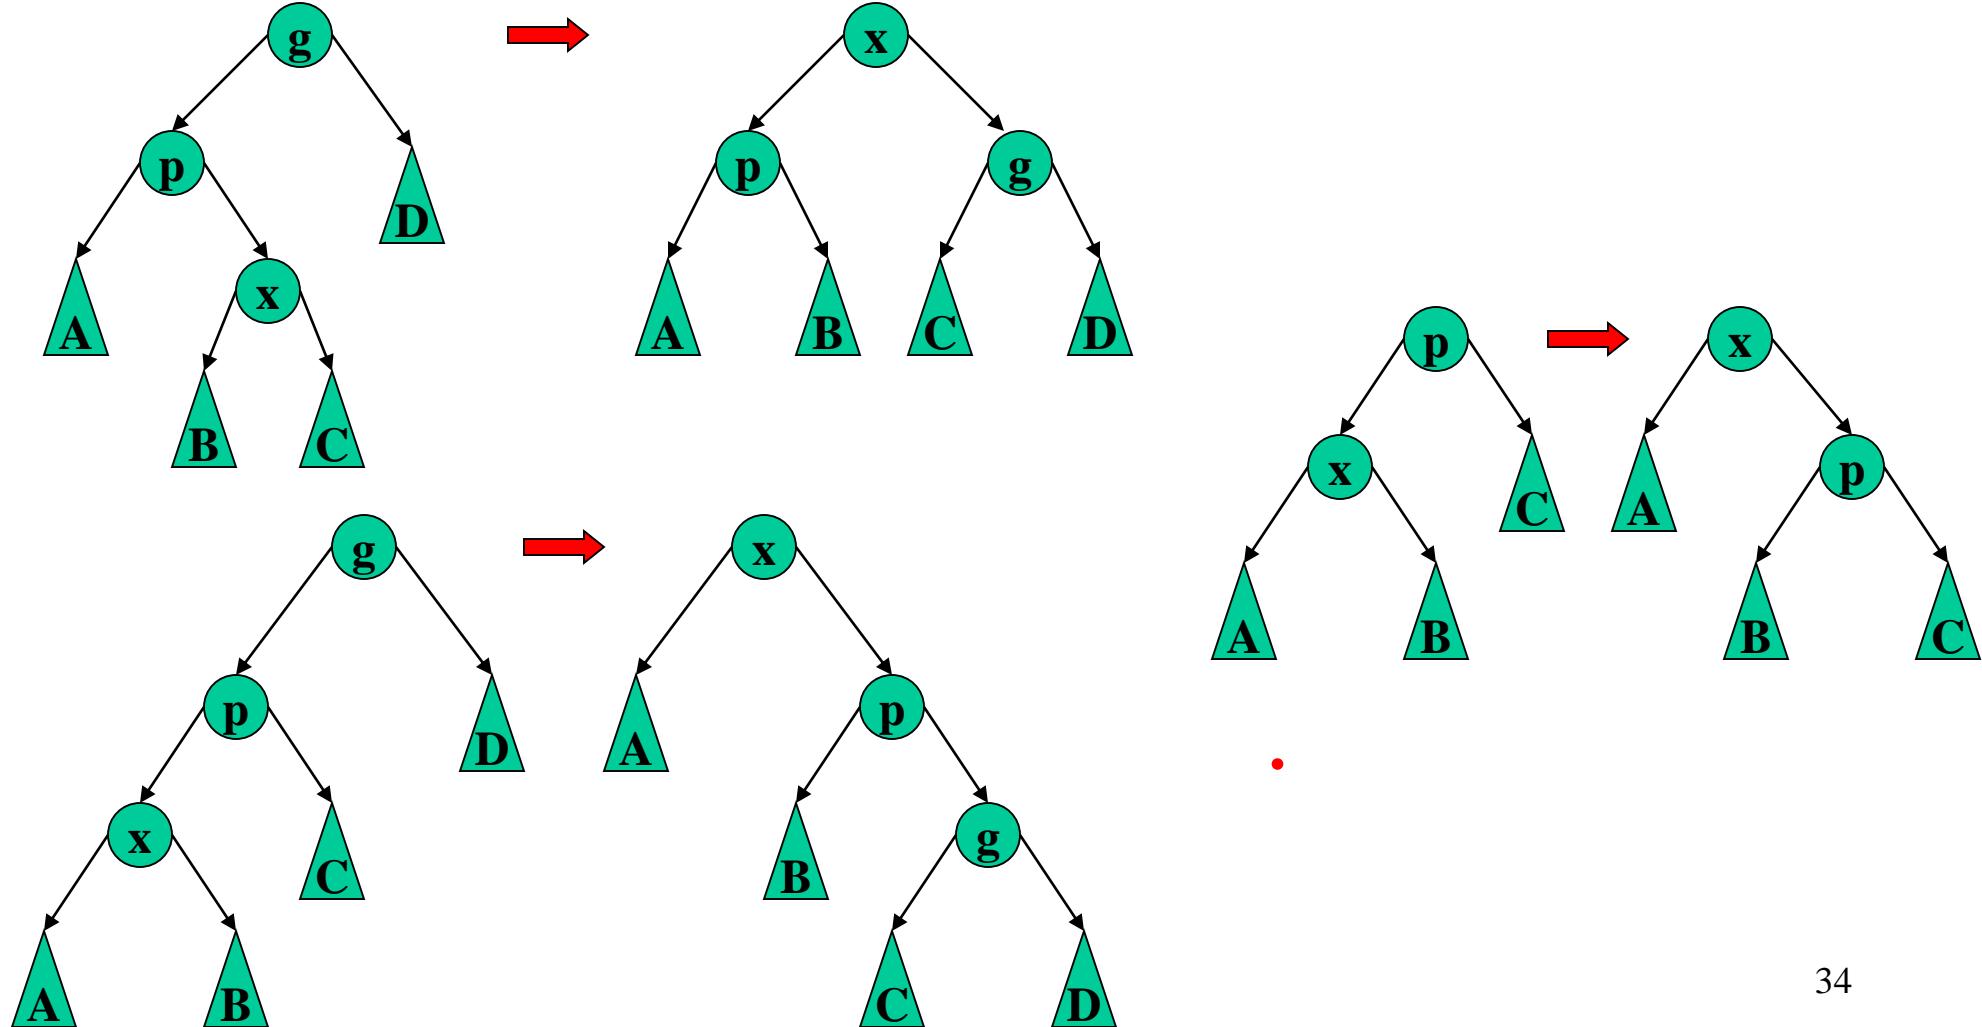
- **изменения цвета узлов**
- **вращений**

Красно-черные деревья



Скошенные деревья

Часто искомые узлы перемещаются ближе к корню за счет одинарных и двойных поворотов. Асимптотическая сложность выполнения M операций вставки и/или поиска составляет $O((N+M)\log_2(N+M))$.



В-деревья

Количество ключей от $M/2$ до $M-1$, количество ссылок на 1 больше. Левая ссылка указывает на узлы, содержащие меньшие ключи – остальные по под диапазонам. Растут вверх. Используются для построения файловых систем, так как позволяют отыскивать искомые узлы за меньшее количество обращений к дереву (соответственно диску).

Многопутевое дерево поиска, построенное на основе k -узлов – узлов, содержащих упорядоченный набор $k-1$ ключей и соответствующих им k указателей на дочерние k -узлы. Если v_0, v_1, \dots, v_{k-2} – ключи, p_0, p_1, \dots, p_{k-1} – указатели, то $p_i, i \in [0; k-2]$ указывает на узлы, ключи которых меньше v_i , а $p_i, i \in [1; k-1]$ указывает на узлы, ключи которых больше v_{i-1} . В-дерево порядка M – это дерево, содержащее k -узлы, $k \in [M/2; M]$ (для корня $k \in [2; M]$), длина пути от корня до любого листа в котором одинакова. Для В-дерева порядка M и высоты h количество **ключей**:

$$N \in [2(M/2)^{h-1}; M^h].$$

Параметр M имеет обычно достаточно большое значение, так как В-деревья и их разновидности широко используются для хранения данных на внешних носителях. Некоторые реализации В-деревьев предполагают наличие указателей на «братьев» – соседние узлы.

B-деревья. Представление узла.

```
struct BNode {  
    Key Data[M] ;  
    struct BNode * Childs[M+1] ;  
    int Count;  
};
```

B-деревья. Операции

Поиск: бинарный поиск по странице, возможно с переходом к поддереву.

Вставка: 1. Поиск узла для вставки. 2. Если ключей меньше $M-1$, то осуществляется вставка. 3.1. Иначе происходит расщепление заполненного узла на два $M/2$ -узла с перемещением центрального элемента на уровень выше. Этот процесс может продолжать рекурсивно, вплоть до корня. 3.2 Расщепление заполненных узлов можно осуществлять при поиске страницы, тем самым устраняя необходимость рекурсивного возврата. 4. B-деревья растут вверх!

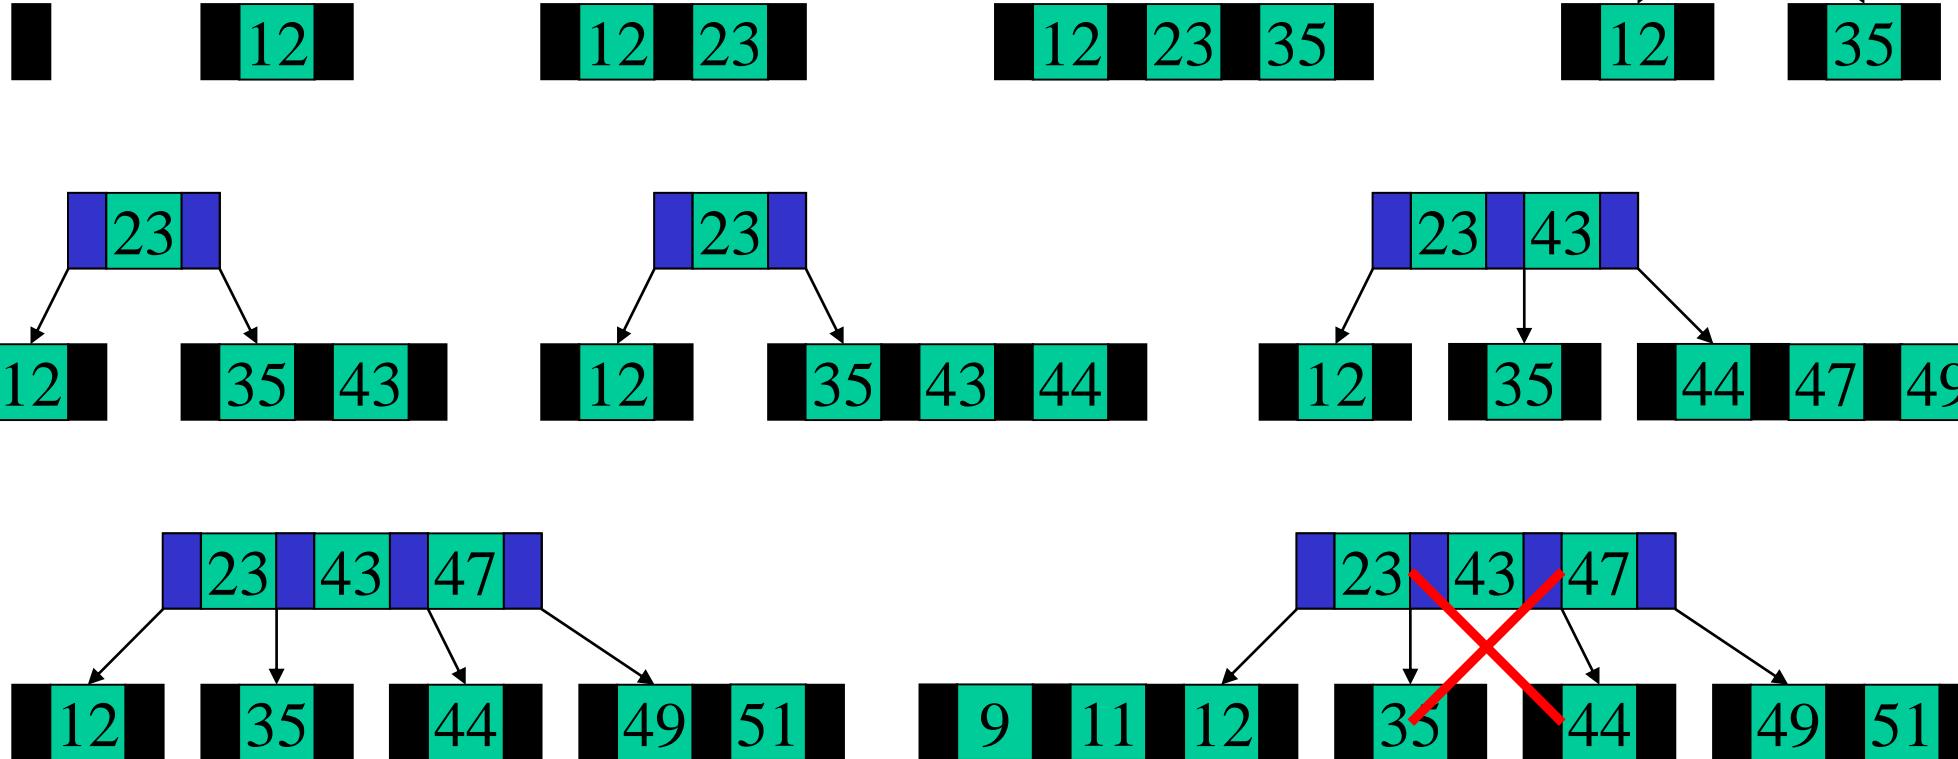
Удаление: 1. Удаление осуществляется только из листьев. Если ключ не в листе, то необходимо найти минимального справа (максимального слева), обменять местами и удалить. 2. Если ключей больше $M/2$, то удаление элементарно. 3. Если сумма ключей в листовых соседних страницах больше $M-1$, то выполняется переливание. 4. Иначе – слияние.

Для пунктов 3,4 – средний из страницы-предка.

2-3-4-деревья

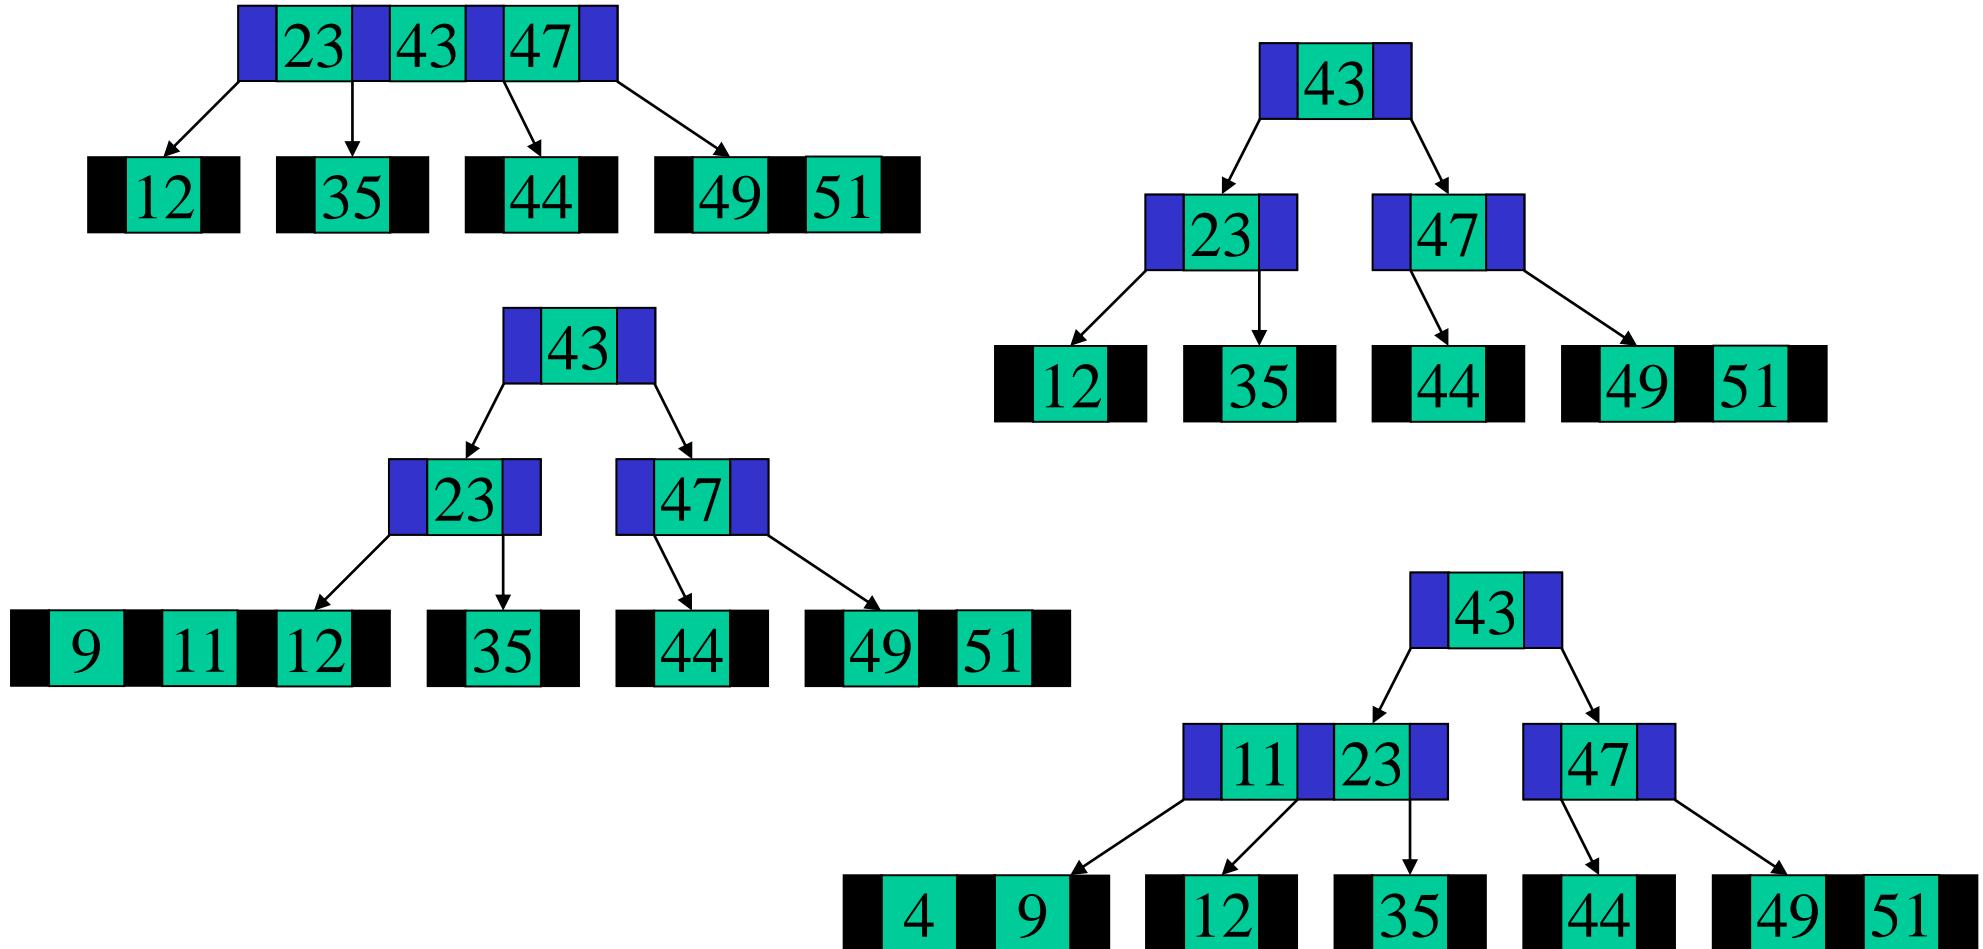
Частный случай В-деревьев – $M = ?$ В пустое дерево вставляются ключи:

12, 23, 35, 43, 44, 47, 49, 51, 11, 9, 4



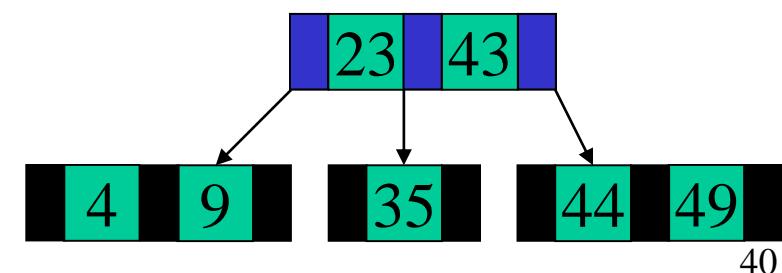
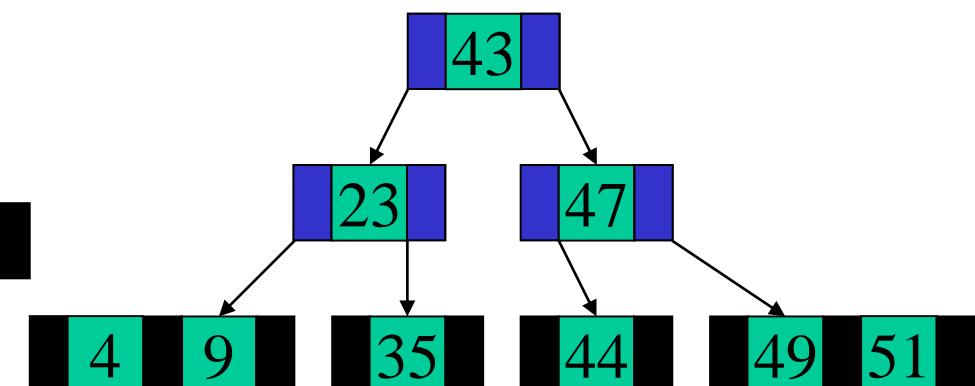
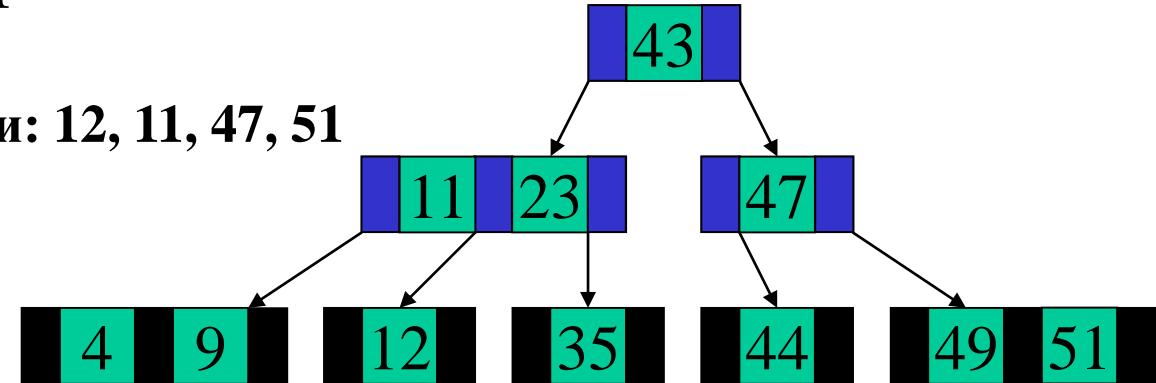
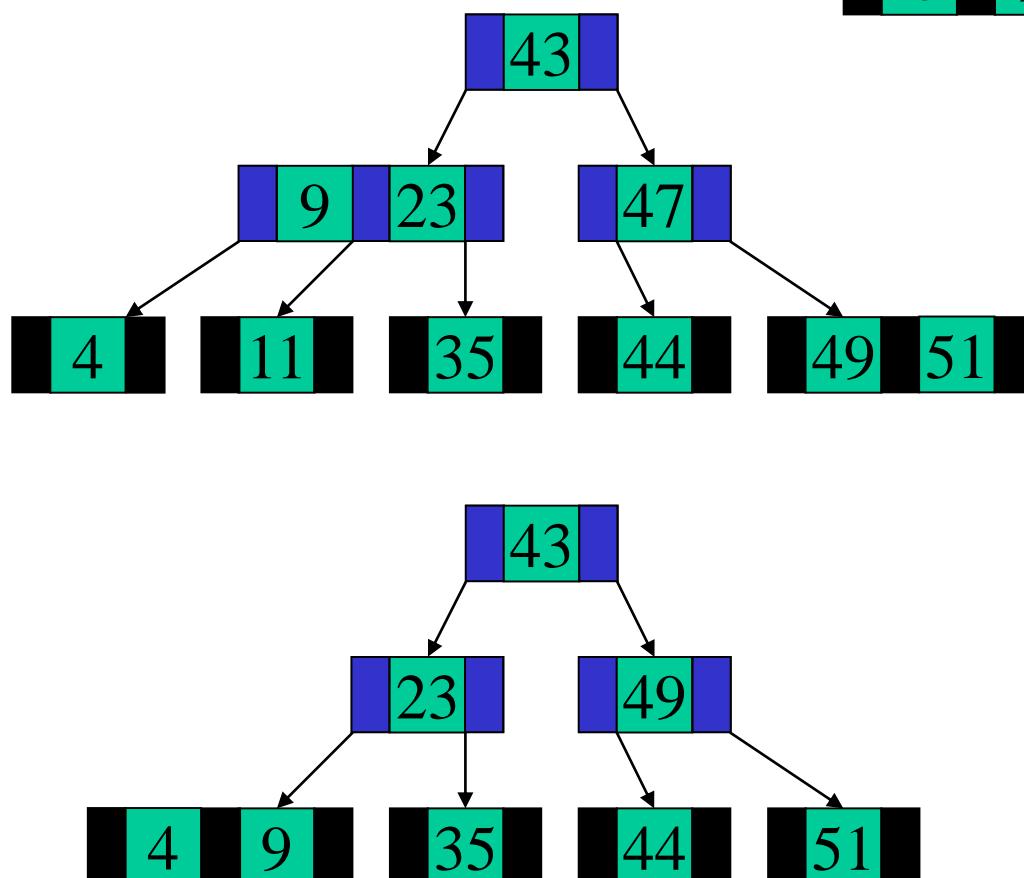
2-3-4-деревья. Вставка

В пустое дерево вставляются ключи: 12, 23, 35, 43, 44, 47, 49, 51, 11, 9, 4



2-3-4-деревья. Удаление

Из дерева удаляются ключи: 12, 11, 47, 51



B*-деревья

Подвид B-деревьев, отличается заполнением узлов от $2M/3$ до M . Обеспечивают более эффективный поиск при усложнении алгоритмов вставки/удаления.

B*-деревья это разновидность **B-деревьев**, в которых количество связей принадлежит диапазону $[2M/3; M]$. В при добавлении ключа, в тот момент когда страница заполнена происходит не расщепление узла, а перераспределение ключей с соседней страницей, вплоть до того момента когда и она не заполнится. После этого происходит расщепление двух страниц на три. Корень такого дерева заполняется до $4M/3$, после чего расщепляется на две страницы.

B+-деревья

Подвид B-деревьев. Данные хранятся только в листьях (во внешних узлах), во внутренних узлах (кроме листьев) – только копии некоторых ключей из листьев.

B+ – деревья это разновидность **B-деревьев**, в которых данные хранятся только во внешних ключах, а внутренние узлы содержат только копии некоторых из ключей, хранящихся в листьях. Для B^+ -дерева порядка M построенного из N ключей количество зондирований $Z \in [\log_M N; \log_{M/2} N]$ и содержит в среднем $N / (\ln 2 * M) = 1,44N/M$ узлов (страниц).

Цифровые деревья поиска

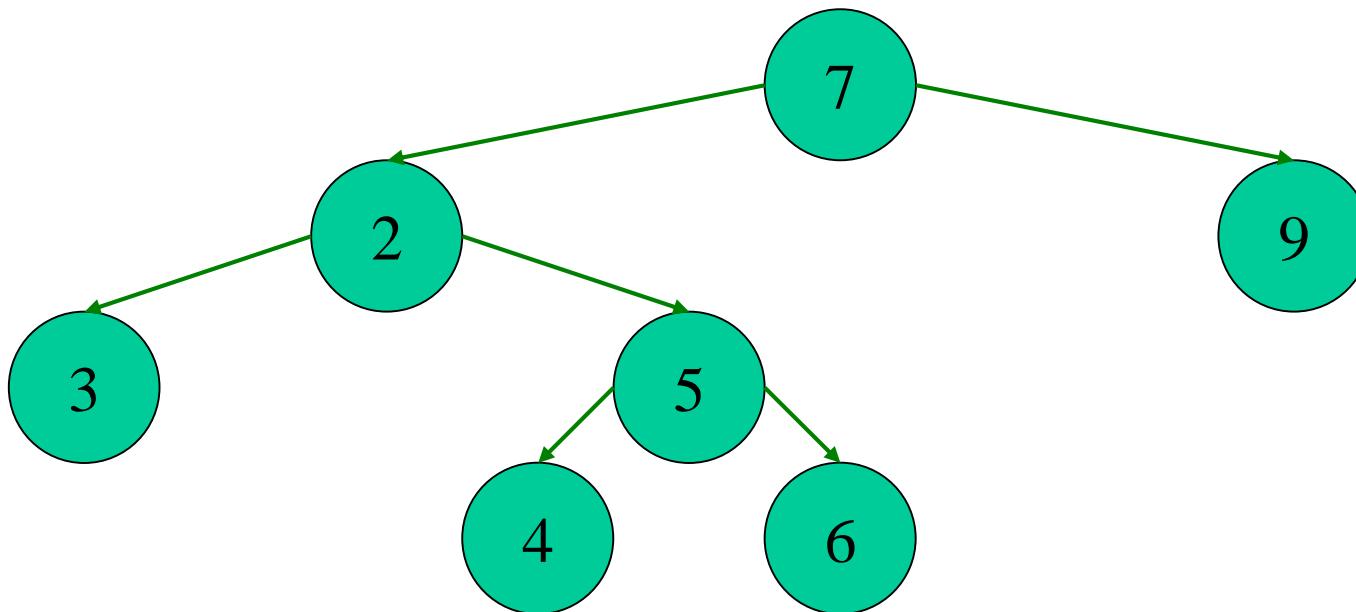
Цифровое дерево поиска (ЦДП) – это бинарное дерево, в котором, в отличие от бинарного дерева поиска, ветвление осуществляется не в соответствии с результатом сравнения полных ключей, а в соответствии с выбранными [двоичными?] разрядами ключа.

Для ЦДП не выполняется условие упорядоченности.

Максимальная длина пути: в среднем – $\log_2 N$, в худшем – $2\log_2 N$.

ЦДП имеет смысл использовать, если $N \ll 2^w$, а если эти значения сопоставимы, то лучше использовать ключи как индексы.

Цифровые деревья поиска



7	0111
2	0010
3	0011
5	0101
4	0100
6	0110
9	1001

Боры, словари (trie-деревья)

ЦПД, в котором ключи хранятся в листьях, а внутренние узлы содержат ссылки на левое и правое поддеревья, с ключами, начинающимися соответственно с 0 или 1 разряда.

Построение бора описывается следующими правилами:

** 0 ключей – внешний узел;

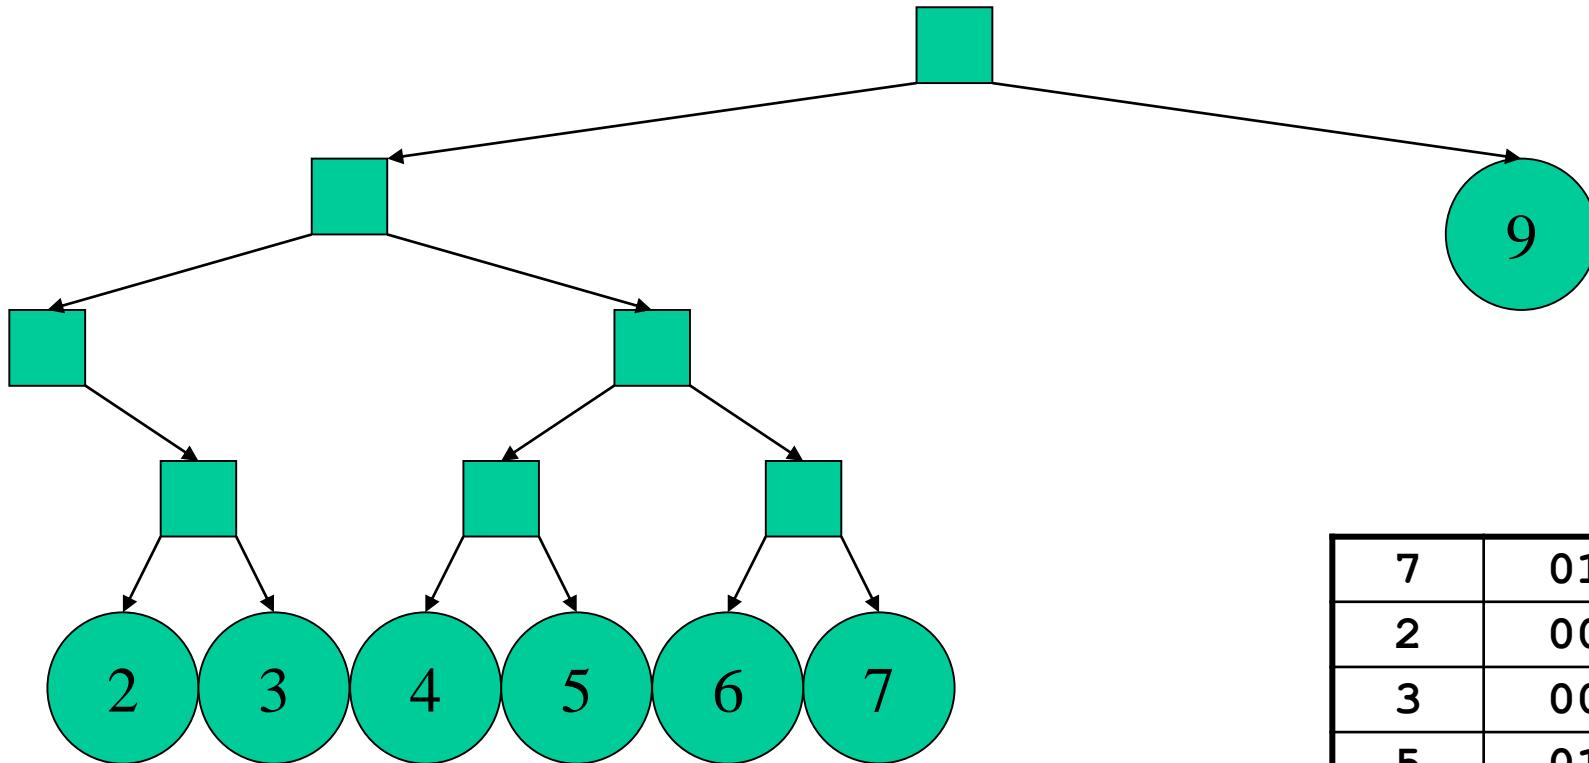
** 1 ключ – корень;

** >> 1 – это ЦПД, корень которого указывает на левое и правое поддеревья, с ключами начинающимися соответственно с нулевого и единичного разрядов в текущей позиции (начиная со старшей).

Структура бора не зависит от порядка добавления ключей. Бор построенный из N случайных ключей содержит в среднем $N/\ln 2 = 1,44N$ узлов.

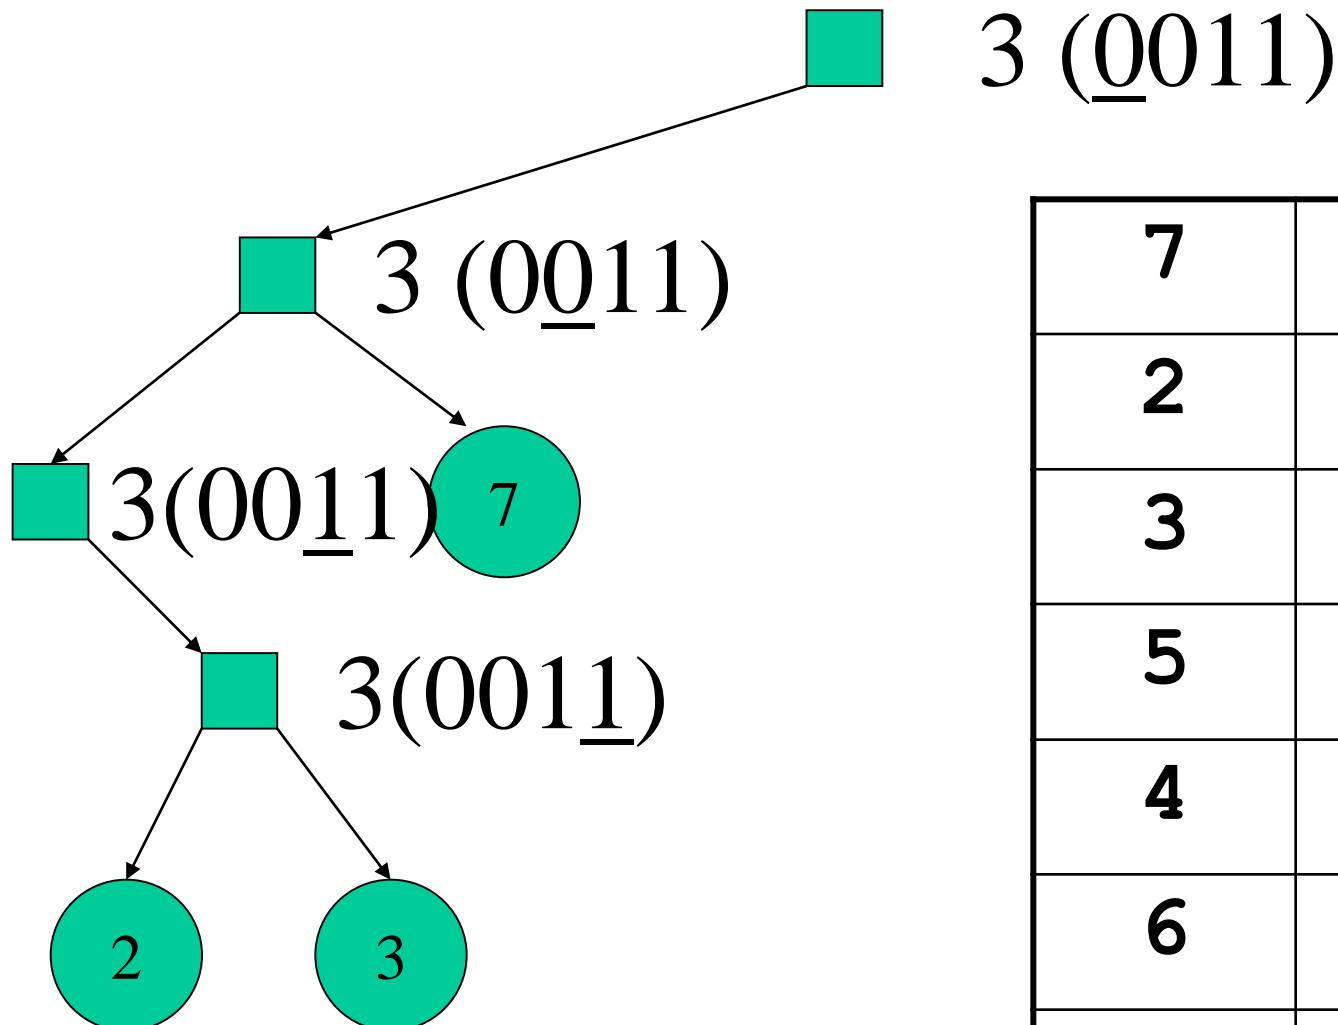
Поиск: в среднем $O(\log_2 N)$, в худшем – $O(w)$, w – количество разрядов. Для ключей переменной длины: префикс любого ключа не должен совпадать с ключом.

Боры, словари (trie-деревья)



7	0111
2	0010
3	0011
5	0101
4	0100
6	0110
9	1001

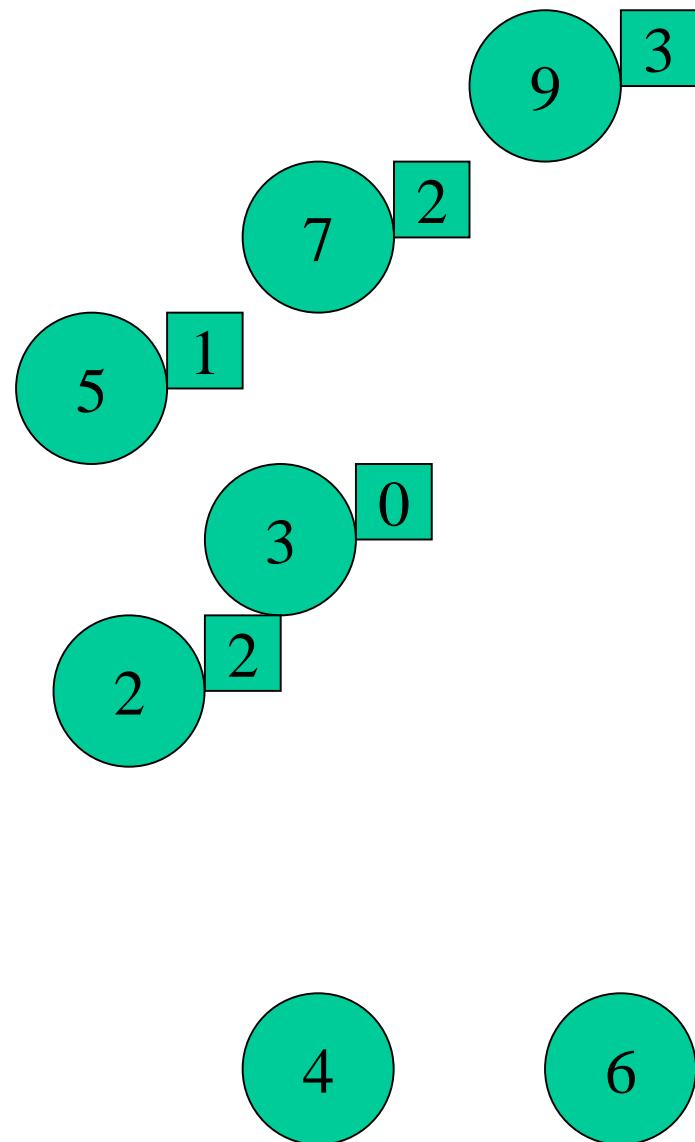
Боры, словари (trie-деревья)



Patricia-деревья

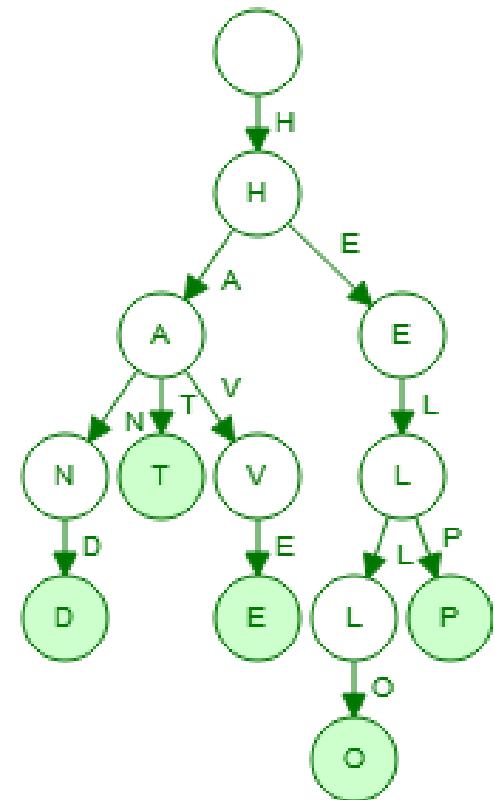
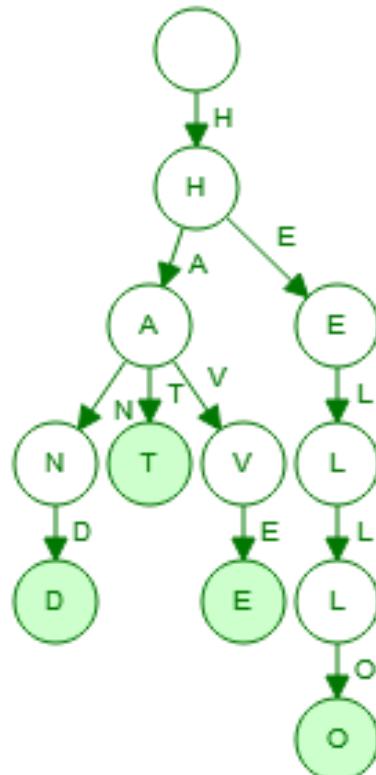
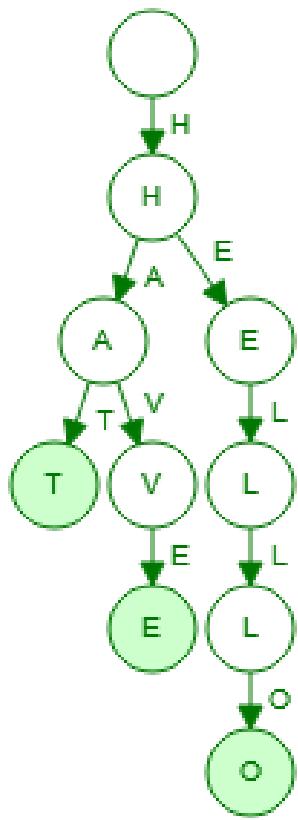
Это бор, в котором хранится индекс (номер) проверяемого разряда, что позволяет (по сравнению с борами) использовать идентичные типы узлов и сократить длину пути от корня до узлов, содержащих ключи.

Patricia-деревья



7	0111
2	0010
3	0011
5	0101
4	0100
6	0110
9	1001

Многопутевые trie-деревья



Patricia-деревья

